1. Desenvolvimento da Base Sintética e Escolha do Modelo

O objetivo da Parte 1 da Fase 6 ('Coração Sob Controle') foi desenvolver um modelo supervisionado de aprendizado de máquina capaz de prever situações de pico de risco assistencial e colapso operacional hospitalar. Para garantir reprodutibilidade científica (`np.random.seed(42)`), foi gerada uma base sintética com 5.000 registros (`assets/base_sintetica_risco_fase6.csv`) contemplando dez variáveis preditoras: `idade_media`, `carga_sistema`, `tempo_espera`, `fc_media`, `spo2_media`, `pa_sistolica`, `temperatura`, `densidade_eventos`, `eventos_24h` e `disponibilidade_recursos`.

A variável-alvo binária `pico_risco` (0 = operação normal; 1 = pico de risco) foi definida a partir da soma de seis condições críticas (`carga_sistema > 80`, `tempo_espera > 60`, `spo2_media < 92`, `fc_media > 110`, `eventos_24h > 4` e `disponibilidade_recursos < 40`), classificando como `pico_risco = 1` todo cenário com `risk_score >= 2`. O conjunto foi particionado de forma estratificada em 80% para treinamento (4.000 amostras) e 20% para teste (1.000 amostras).

Foram treinados e comparados três algoritmos de classificação: Regressão Logística (com padronização `StandardScaler`), Gradient Boosting e Random Forest (`n_estimators=200`, `random_state=42`). O algoritmo Random Forest foi selecionado como modelo final por atingir o melhor desempenho global e capturar com exatidão as fronteiras de decisão não lineares e combinatórias entre variáveis clínicas e operacionais.

2. Resultados Comparativos e Análise da Matriz de Confusão

Algoritmo Avaliado	Acurácia	Precisão	Recall	F1-Score
Random Forest (Selecionado)	0.9990 (99,9%)	1.0000 (100%)	0.9962 (99,6%)	0.9981
Gradient Boosting	0.9980 (99,8%)	1.0000 (100%)	0.9925 (99,3%)	0.9962
Regressão Logística	0.8160 (81,6%)	0.6934 (69,3%)	0.5526 (55,3%)	0.6151

No conjunto de teste (1.000 registros), o Random Forest classificou corretamente 999 casos, obtendo Acurácia de 99,90%, Precisão de 100%, Recall de 99,62% e F1-Score de 99,81%. Em gestão de crises hospitalares, o Recall (sensibilidade) é a métrica mais crítica, pois um Falso Negativo significa deixar de acionar protocolos de contingência diante de uma crise real.

Matriz de Confusao	Previsto: Classe 0	Previsto: Classe 1
Real: Classe 0 (Normal)	734 (VN)	0 (FP)
Real: Classe 1 (Risco)	1 (FN)	265 (VP)

3. Calibração de Probabilidades (Brier Score) e Importância das Variáveis

Além da classificação binária, o sistema multiagente depende da probabilidade estimada (`predict_proba`) para quantificar a severidade do alerta. A qualidade probabilística do Random Forest foi avaliada por meio da curva de calibração e do Brier Score, que atingiu o valor de 0,0058 no conjunto de teste. Como o Brier Score mede o erro quadrático médio entre as probabilidades previstas e os desfechos observados (variando de 0 a 1, onde 0 é perfeito), o resultado de 0,0058 confirma alta aderência das probabilidades geradas no domínio sintético estudado.

A análise de importância das variáveis (`feature_importances_`) confirmou que o modelo priorizou exatamente os indicadores determinantes da regra geradora de crise: `disponibilidade_recursos`, `tempo_espera`, `carga_sistema`, `fc_media`, `spo2_media` e `eventos_24h`, demonstrando coerência interna entre o aprendizado estatístico e os limiares operacionais hospitalares.

4. Limitações do Experimento e Melhorias Futuras

A principal limitação metodológica deste experimento reside na utilização de dados sintéticos governados por regras determinísticas. Como os rótulos de `pico_risco` foram derivados de limiares objetivos sem ruído estocástico clínico complexo, algoritmos baseados em árvores de decisão conseguem reconstruir quase perfeitamente a função geradora (explicando a acurácia de 99,9%).

Portanto, o score produzido pelo modelo não deve ser interpretado isoladamente como uma probabilidade clínica validada para pacientes reais. Como melhorias futuras para implantação em produção hospitalar, recomendam-se: (i) retreinamento e validação externa com prontuários eletrônicos e indicadores reais anonimizados sob aprovação ética (CEP/LGPD); (ii) calibração isotônica ou sigmóide (Platt Scaling) em coortes multicêntricas; e (iii) monitoramento contínuo de data drift e ajuste do limiar de decisão para zerar falsos negativos em cenários críticos.

5. Serialização, Base de Conhecimento e Teste com Novo Caso

O modelo final foi serializado no arquivo `config/modelo_risco_cardiaco.joblib` via `joblib.dump` e submetido ao caso de teste oficial da FIAP (`idade_media=62`, `carga_sistema=92`, `tempo_espera=75`, `fc_media=118`, `spo2_media=89`, `pa_sistolica=100`, `temperatura=37.5`, `densidade_eventos=7`, `eventos_24h=5`, `disponibilidade_recursos=25`).

```
Resultado da Inferência no Caso de Teste (modelo_risco_cardiaco.joblib):
- Classe prevista (predict)       : 1 (Pico de Risco Ativo)
- Score estimado (predict_proba)  : 0.96 (96% de probabilidade estimada)
- Base de Protocolos exportada    : config/protocolos_emergencia.json (10 protocolos)
```

Conclui-se que todas as etapas da Parte 1 foram cumpridas com rigor técnico, deixando o modelo preditivo `.joblib` e a base de conhecimento `.json` prontos e validados para consumo direto pelas tools da arquitetura multiagente na Parte 2.